

DESAFIO 06 – PREVISÃO DE CONSUMO DE ENERGIA ELÉTRICA

1. Introdução

O objetivo deste trabalho foi desenvolver modelos de regressão capazes de prever o consumo de energia elétrica residencial a partir da variável **Global Active Power**, utilizando dados do conjunto *Household Electric Power Consumption* disponibilizado pelo UCI Machine Learning Repository.

A previsão de consumo energético possui aplicações importantes em planejamento de demanda, otimização da distribuição elétrica e desenvolvimento de sistemas inteligentes de gerenciamento de energia. Foram aplicadas técnicas de análise exploratória, engenharia de atributos e modelagem preditiva com algoritmos de aprendizado de máquina supervisionado.

2. Análise Exploratória dos Dados

O dataset original contém **2.075.259 registros** com medições por minuto entre dezembro de 2006 e novembro de 2010. Após agregação horária, tratamento de valores ausentes e remoção de outliers pelo método IQR (2,1% dos registros), o conjunto final ficou com **33.412 amostras horárias**.

A análise exploratória revelou os seguintes padrões:

- Distribuição assimétrica à direita da variável-alvo, com maior concentração em baixos valores de consumo;
- Picos de consumo no período noturno (principalmente entre 18h e 22h) e mínimos na madrugada;
- Variabilidade sazonal com consumo mais elevado nos meses de inverno (novembro a março);
- Forte correlação positiva entre `Global_active_power` e as variáveis `Global_intensity` e `Sub_metering_3`.

3. Pré-processamento dos Dados

As etapas de preparação dos dados incluíram:

- Conversão de Date e Time para índice datetime e agregação por média horária;
- Extração de atributos temporais: hora do dia, dia da semana, mês e indicador de fim de semana;
- Criação de variáveis defasadas: `lag_1h` (consumo 1 hora antes) e `lag_24h` (consumo 24 horas antes);
- Remoção de 732 outliers (2,1%) pelo critério IQR ($Q1 - 1,5 \times IQR$, $Q3 + 1,5 \times IQR$);
- Divisão cronológica sem embaralhamento: 70% treino / 15% validação / 15% teste;
- Padronização das features com `StandardScaler` ajustado exclusivamente no conjunto de treino.

A divisão resultou em: **23.388 amostras** para treino (dez/2006 a set/2009), **5.012** para validação (set/2009 a abr/2010) e **5.012** para teste (abr/2010 a nov/2010).

4. Modelagem e Resultados

Foram avaliados três modelos de regressão supervisionada, todos treinados com as mesmas 12 features e avaliados no conjunto de teste:

- **Regressão Linear:** modelo paramétrico que assume relação linear entre features e target;
- **Regressão Polinomial (grau 2):** extensão da regressão linear com termos quadráticos e interações;
- **Random Forest Regressor:** ensemble de árvores de decisão com agregação por média (bagging).

Resultados no Conjunto de Teste:

Modelo	MAE	RMSE	R ²	MAPE (%)
Regressão Linear	0.0131	0.0209	0.9991	1.83%
Regressão Polinomial (grau 2)	0.3491	0.4866	0.4901	48.35%
Random Forest	0.0133	0.0221	0.9989	1.86%

Nota: linha verde = melhor resultado por métrica; linha vermelha = pior desempenho. A Regressão Linear e o Random Forest obtiveram métricas praticamente equivalentes; o Random Forest foi escolhido como modelo final por sua robustez e capacidade de capturar relações não-lineares. A validação cruzada temporal (TimeSeriesSplit, 5 folds) confirmou a estabilidade: R² médio de 0,9993 (±0,0001) para o Random Forest.

Configuração do Random Forest:

Parâmetro	Valor	Justificativa
n_estimators	200	Maior número de árvores reduz variância
max_depth	15	Limita profundidade para evitar overfitting
min_samples_leaf	5	Exige mínimo de amostras nas folhas
random_state	42	Reprodutibilidade dos resultados
n_jobs	-1	Usa todos os núcleos disponíveis

5. Discussão Metodológica e Limitações

Embora os resultados obtidos tenham sido numericamente excelentes, uma análise metodológica mais aprofundada revelou uma limitação importante no processo de modelagem: a presença de **data leakage** (vazamento de informação).

Durante a construção do conjunto de atributos, foram utilizadas variáveis medidas no mesmo instante temporal da variável-alvo `Global_active_power`, com elevada correlação física e estatística:

Categoria	Variáveis	Disponível em produção
Contemporâneas (leakage)	Global_reactive_power, Voltage, Global_intensity, Sub_metering_1, Sub_metering_2, Sub_metering_3	NÃO
Genuinamente preditivas	hour, day_of_week, month, is_weekend, lag_1h, lag_24h	SIM

Na prática, ao tentar prever o consumo *futuro*, as variáveis contemporâneas ainda não estariam disponíveis. O modelo teve acesso a informações do mesmo instante da medição alvo, tornando a tarefa artificialmente mais simples. Isso explica, em parte, os valores de R^2 excepcionalmente elevados (0,9991 para Regressão Linear e 0,9989 para Random Forest).

Portanto, os resultados devem ser interpretados com cautela: as métricas refletem a capacidade do modelo de reconstruir o consumo do mesmo instante, não de prever consumo genuinamente futuro. Essa limitação foi identificada e documentada, conforme orientação da devolutiva da P1.

6. Importância das Variáveis

A análise de importância do Random Forest demonstrou que os atributos diretamente relacionados ao consumo elétrico tiveram grande influência nas previsões. É importante distinguir os dois grupos:

Grupo	Variáveis de Maior Importância	Observação
Contemporâneas (leakage)	Global_intensity, Sub_metering_3, Global_reactive_power	Alta correlação com target
Genuinamente preditivas	lag_1h, lag_24h, hour	Informação genuinamente prospectiva

7. Conclusão

O estudo demonstrou a aplicação de técnicas de aprendizado de máquina para previsão de consumo energético residencial, destacando o **Random Forest Regressor** como o modelo com melhor desempenho geral entre os três algoritmos avaliados, com $R^2 = 0,9989$, MAE = 0,0133 kW e RMSE = 0,0221 kW no conjunto de teste.

A Regressão Linear apresentou resultados comparáveis ($R^2 = 0,9991$), sugerindo que, dado o contexto de data leakage presente, relações lineares entre as variáveis contemporâneas e o target já são suficientes para explicar grande parte da variância. A Regressão Polinomial de grau 2, por sua vez, gerou overfitting severo no conjunto de treino e desempenho muito inferior no teste ($R^2 = 0,4901$), sendo descartada como modelo final.

A análise crítica dos resultados revelou a presença de **data leakage** decorrente da utilização de variáveis medidas simultaneamente ao consumo alvo. Essa característica contribuiu para métricas elevadas e limita a interpretação do desempenho como capacidade real de previsão futura. O grupo optou por manter o modelo original e documentar essa limitação de forma explícita, conforme orientado na devolutiva da P1.

Como trabalho futuro, recomenda-se reconstruir o modelo utilizando exclusivamente variáveis históricas e temporais (lags e features de tempo), eliminando as variáveis contemporâneas. Essa abordagem permitirá uma avaliação mais rigorosa da capacidade preditiva genuína e produzirá resultados mais representativos de um cenário operacional real.

Resumo Executivo

Item	Detalhe
Dataset	UCI Household Electric Power Consumption (2006–2010)
Registros utilizados	33.412 amostras horárias (após limpeza)
Divisão	70% treino / 15% validação / 15% teste (cronológica)
Modelos avaliados	Regressão Linear, Polinomial (grau 2), Random Forest
Modelo final	Random Forest (n_estimators=200, max_depth=15)
R^2 no teste	0,9989
MAE no teste	0,0133 kW
RMSE no teste	0,0221 kW
Limitação principal	Data leakage por uso de variáveis contemporâneas ao target
Modelo salvo	modelo_final.joblib + scaler.joblib
App publicado	Streamlit Community Cloud